

From Human-Centric to Machine-Optimized: A Technolinguistic Analysis of Documentation Readability in IIm.txt Standards

Proposal & Kerangka Kerja Komprehensif Publikasi Ilmiah untuk CoDHES Conference

Profil Peneliti: Lulusan Magister Sistem Informasi (M.SI) & Software Engineer

Fokus Topik: Technolinguistics / Digital Humanities

Metodologi: Kuantitatif Komputasional (Berbasis JavaScript)

1. Justifikasi Metodologi Penelitian

Penelitian ini menggunakan pendekatan **Kuantitatif Komputasional**. Meskipun pengumpulan data dilakukan melalui mekanisme otomatisasi seperti *web scraping* atau *API fetching* tanpa menyebarkan kuesioner kepada responden manusia, penelitian ini secara mutlak diklasifikasikan sebagai penelitian kuantitatif berdasarkan pilar akademik berikut:

- **Transformasi Data Numerik:** Esensi utama dari metode kuantitatif adalah mengubah fenomena kualitatif (teks/bahasa) menjadi representasi metrik numerik yang eksak dan objektif melalui formula matematis.
- **Objektivitas dan Replikabilitas:** Proses evaluasi tidak menggunakan interpretasi subjektif peneliti, melainkan kalkulasi algoritma yang baku. Jika penelitian ini direplikasi oleh pihak lain menggunakan korpus data yang sama, hasil angka statistik yang diperoleh akan 100% identik.
- **Unit Analisis Makro:** Unit analisis dalam riset ini bukan jumlah berkas, melainkan jumlah kata, suku kata, kalimat, dan token unik. Dengan mengekstrak dokumen dokumentasi berskala besar, total titik data yang diolah dapat mencapai puluhan ribu entitas kebahasaan, memenuhi kaidah kekuatan data statistik deskriptif.

Definisi Operasional Metode Akademik:

Dalam bab metodologi, pendekatan ini secara resmi disebut sebagai **Quantitative Content Analysis** yang dikombinasikan dengan **Computational Linguistics** (Linguistik Komputasional).

2. Konsep Riset & Paradoks Keterbacaan IIm.txt

Di era kecerdasan buatan, model bahasa besar (LLM) seperti GPT-4, Claude, dan Gemini secara masif mengonsumsi dokumentasi teknis. Muncul sebuah standar baru di industri teknologi yang disebut berkas `IIm.txt`—sebuah berkas teks ringkas yang diletakkan di *root directory* sebuah platform teknologi untuk mempermudah agen AI melakukan *crawling* dan memahami konteks instruksi sistem secara cepat.

Fenomena ini melahirkan kajian **Technolinguistics** yang sangat menarik: *Bagaimana manusia sengaja mendekonstruksi struktur bahasanya sendiri agar lebih mudah dipahami oleh mesin, bukan oleh manusia lain?*

Melalui riset ini, versi dokumen konvensional (Human-Centric HTML) akan dibandingkan secara berpasangan dengan versi berkas `llm.txt` (Machine-Optimized Plain Text). Eksperimen ini mengukur "Paradoks Keterbacaan", di mana hilangnya redundansi bahasa membuat teks menjadi sangat sulit dipahami secara kognitif oleh manusia, namun sangat efisien secara biaya dan arsitektur token bagi model AI.

3. Spesifikasi Arsitektur Alat Bantu JavaScript

Guna mendukung objektivitas penelitian, dikembangkan sebuah artefak perangkat lunak berupa aplikasi atau skrip berbasis lingkungan **JavaScript (Node.js)** yang mengekstrak data sekaligus menghitung nilai kebahasaan secara instan melalui pustaka berikut:

3.1 Pustaka Ekstraksi Data (Scraping & Fetching)

- `fetch` (Native Node.js): Digunakan untuk mengunduh berkas plain text `llm.txt` langsung dari root domain target secara instan.
- `puppeteer` atau `playwright`: Digunakan sebagai *headless browser* untuk merender halaman dokumentasi manusia yang berbasis Single Page Application (SPA) seperti Docusaurus atau Nextra, lalu mengambil teks bersih (`innerText`) tanpa mengikuti komponen navigasi.

3.2 Pustaka Analisis Kebahasaan (Computational Metrics)

- `text-readability`: Menghitung skor *Flesch Reading Ease* (FRE) dan *Flesch-Kincaid Grade Level* (FKGL).
- `stopword`: Pustaka untuk menyaring dan membuang kata-kata fungsi (seperti *the, is, at, which*) guna menghitung kepadatan leksikal.
- `@js-tiktoken`: Porting resmi tokenisasi OpenAI untuk menghitung jumlah token riil yang dihasilkan teks berdasarkan pengodean model GPT-4 (`cl100k_base`).

3.3 Formula Metrik Operasional

Kepadatan Leksikal (Lexical Density) dihitung secara matematis menggunakan rumus sebagai berikut:

$$\text{Lexical Density} = (\text{Jumlah Kata Inti} / \text{Total Kata}) \times 100\%$$

Sedangkan efisiensi mesin dihitung berdasarkan Rasio Token terhadap Kata:

$$\text{Token-to-Word Ratio} = \text{Jumlah Token LLM} / \text{Total Kata Teks}$$

Berikut adalah visualisasi implementasi logika pengolah data utama menggunakan JavaScript:

```

const readability = require('text-readability');
const sw = require('stopword');
const { getEncoding } = require('js-tiktoken');

function analyzeTechnolinguistic(rawText) {
  const words = rawText.split(/\s+/);

  // 1. Hitung Metrik Manusia (Flesch Score)
  const freScore = readability.fleschReadingEase(rawText);

  // 2. Hitung Kepadatan Leksikal
  const contentWords = sw.removeStopwords(words);
  const lexicalDensity = (contentWords.length / words.length) * 100;

  // 3. Hitung Efisiensi Token Model AI
  const enc = getEncoding("cl100k_base");
  const tokenCount = enc.encode(rawText).length;
  const tokenRatio = tokenCount / words.length;

  return {
    fleschScore: freScore.toFixed(2),
    lexicalDensityPercent: lexicalDensity.toFixed(2),
    tokenCount: tokenCount,
    tokenPerWord: tokenRatio.toFixed(2)
  };
}

```

4. Strategi Pengambilan Sampel (Sampling)

Penelitian ini menggunakan metode **Purposive Sampling** dengan menetapkan batasan korpus data sebanyak **5 platform teknologi terkemuka (Total 10 dokumen berpasangan)**. Jumlah sampel ini dinilai sangat ideal dan kokoh untuk skala paper konferensi eksploratif karena:

1. **Faktor Pionir Teknologi:** Berkas `llm.txt` merupakan standar baru; membedah 5 raksasa teknologi adopsi awal (*early adopters*) sudah mewakili arah tren arsitektur data global.
2. **Kekayaan Titik Data Intern:** Karena analisis dilakukan per kata/token, 10 dokumen komprehensif tersebut mengandung agregat lebih dari 30.000 korpus kata yang siap diolah secara statistik.

No	Kategori Industri	Kandidat Platform Teknologi	Sumber Data A (Manusia)	Sumber Data B (LLM)
1	Web Framework	FastAPI	HTML Tutorial Guide	/llm.txt (Plain Text)
2	AI Orchestration	LangChain	HTML Core Concepts	/llm.txt (Plain Text)
3	Backend-as-a-Service	Supabase	HTML Reference Manual	/llm.txt (Plain Text)
4	Deployment Platform	Vercel	HTML Integration Docs	/llm.txt (Plain Text)
5	Developer Utilities	Stripe / GitHub API	HTML Getting Started	/llm.txt (Plain Text)

5. Outline Lengkap Struktur Paper Konferensi

Berikut adalah kerangka penulisan naskah final publikasi ilmiah yang siap diajukan ke penelaah konferensi:

HALAMAN JUDUL & ABSTRAK (Bilingual / English)

- **Struktur Abstrak:** Memuat ringkasan otomatis yang terdiri dari *Context* (Tren AI & DX), *Problem* (Redundansi bahasa vs efisiensi token), *Objective* (Komparasi keterbacaan), *Methodology* (Pendekatan JS komputasional pada 10 dokumen), *Findings* (Penemuan angka paradoks), dan *Implication* (Rekomendasi bagi Technical Writer).

BAB 1: PENDAHULUAN (Introduction)

- **1.1 Latar Belakang:** Pergeseran pemanfaatan dokumentasi dari berpusat pada manusia menjadi konsumsi agen cerdas AI. Kemunculan inovasi standardisasi berkas teks ringkas `llm.txt`.
- **1.2 Rumusan Masalah:** Bagaimana dekonstruksi sintaksis pada berkas optimasi mesin mendistorsi kenyamanan membaca manusia dan meningkatkan efisiensi komputasi LLM?
- **1.3 Kebaruan Penelitian (Novelty):** Mengkaji struktur berkas spesifikasi kecerdasan buatan dari sudut pandang sosiolinguistik digital dan *technolinguistics* makro.

BAB 2: LANDASAN TEORI (Literature Review)

- **2.1 Teori Keterbacaan Klasik:** Penjelasan matematis di balik formula original Rudolf Flesch (1948) mengenai panjang klausa dan jumlah suku kata.
- **2.2 Arsitektur Pengodean Token LLM:** Teori bagaimana tokenisasi BPE (Byte Pair Encoding) mengonversi teks mentah menjadi representasi numerik bernilai ekonomi pada API OpenAI.
- **2.3 Komunikasi Socio-Technical:** Irisan bagaimana sistem informasi memengaruhi perilaku komunikasi teknis tertulis.

BAB 3: METODOLOGI PENELITIAN (Methodology)

- **3.1 Desain Korpus Data:** Tabel daftar rincian 5 entitas teknologi berpasangan.
- **3.2 Implementasi Instrumen:** Skema alur kerja perangkat lunak pengumpul data otomatis berbasis skrip Node.js.
- **3.3 Operasionalisasi Variabel:** Penjelasan standarisasi interpretasi angka FRE (Skor 0-30 berarti 'Sangat Sulit/Akademis', Skor 60-70 berarti 'Standar/Normal').

BAB 4: HASIL DAN PEMBAHASAN (Results and Discussion)

- **4.1 Penyajian Temuan Kuantitatif:** Tampilan grafik radikal perbandingan kontras antara skor FRE dokumen manusia yang tinggi (mudah) dengan berkas LLM yang anjlok (sulit).
- **4.2 Interpretasi Kebahasaan:** Analisis mengapa berkas mesin memiliki kepadatan leksikal (*Lexical Density*) mendekati 90% (karena eliminasi total kata sandang/hubung). Pembuktian matematis penghematan jumlah token (Token Efficiency) mencapai lebih dari 25% bagi AI.
- **4.3 Implikasi Industri:** Panduan aplikatif bagi tim *technical writer* dalam menyusun dokumen teknis modern yang ramah terhadap ekosistem manusia sekaligus mesin.

BAB 5: KESIMPULAN DAN SARAN (Conclusion)

- **5.1 Kesimpulan:** Pembuktian hipotesis bahwa evolusi teknologi melahirkan struktur bahasa pragmatis baru yang menepikan aspek kenyamanan membaca manusia demi kecepatan komputasi mesin.
- **5.2 Saran & Batasan:** Rekomendasi riset lanjutan untuk menguji efisiensi dokumen pada variasi tokenisasi model lokal (Llama/Mistral) serta penyematan alat ukur otomatis ini ke dalam pipa integrasi berkelanjutan (CI/CD Pipeline).